



REGULARIZATION PATHS FOR GENERALIZED LINEAR MODELS VIA COORDINATE DESCENT

J. Friedman T. Hastie R. Tibshirani

Aline Gabrielly Gomes de Freitas
Luiz Eduardo de Souza

Porto Alegre, 01 de setembro de 2026.

Sumário

Introdução

Contextualização

Metodologia

Escolha de Implementação

Definição de Lasso

Por que correlação atrapalha o Coordinate Descent?

A Reformulação

Warm Starts

Active Set

Soft-Threshold

Algoritmo

Critério de Parada

Monte Carlo I

Monte Carlo II

Contribuição

Aplicação

Conclusão

Introdução

- Amplamente utilizado para ajustar modelos lineares, logísticos e multinomiais com penalidades Lasso (L1) e Ridge (L2);
- Popularizado pelo pacote glmnet em R e implementado em `sklearn.linear_model.ElasticNet` e Lasso no Python.
- Poisson foi adicionado ao glmnet posteriormente;
- A grande vantagem desse método é calcular o caminho de regularização de forma extremamente rápida, o que é ideal para seleção de variáveis em dados com altíssima dimensionalidade ($p \gg N$)

Contextualização

Genômica

- 100 pacientes e 20.000 genes;
- O Lasso zera a maioria e devolve 10 ou 15 genes como biomarcador.

Risco de Crédito

- Centenas de variáveis correlacionadas;
- O termo Ridge distribui em vez de eleger, e o score fica estável.

Classificação de Texto

- Bag-of-words gera matrizes esparsas com dezenas de milhares de colunas;
- O coordinate descent explora a esparsidade diretamente.

Contextualização

O Lasso de 2010 é exatamente o de 1996:

- Mesma solução;
- Mesmas propriedades estatísticas;
- Não há estimador novo.

O que mudou?

- Como calcular;
- Escala;
- Confiabilidade.

1996 entregou um estimador

2010 entregou um algoritmo

Metodologia

O artigo de 2010 apresenta 7 componentes implementados:

Pathwise Coordinate
Descent
Seção 2.5, p.7

Covariance Updates
Seção 2.2, p.6

Sparse Updates
Seção 2.3, p.6-7


Weighted Updates
Seção 2.4, p.7

Regularized Logistic
Regression
Seção 3, p.8-9

Regularized
Multinomial Regression
Seção 4, p.9-11

Grouped and Matrix
Responses
Seção 4.2, p.11

Escolha de Implementação



Regularization Path percorrido por Coordinate Descent cíclico com Warm Starts e Active Set.

Coordinate Descent não é novidade

- Atribuições a Fu (1998), Daubechies et al. (2004), Shevade & Keerthi (2003), Van der Kooij (2007) e Wu & Large (2008);
- Observou-se a redescoberta do método várias vezes sem a percepção de seu poder;
- Friedman et al. (2007) foi precursor direto nomeando Parthwise Coordinate Optimization.

O obstáculo do Lasso original não era a qualidade do estimador

- Cada valor do parâmetros de regularização exigia uma execução completa e independente de um otimizador caro;
- Nada era herdado de uma solução para outra;
- Escolher o parâmetro por validação cruzada multiplicava esse custo pelo número de folds.

Definição do Lasso


por Tibshirani - Forma de Restrição

$$\min_{(\beta_0, \boldsymbol{\beta})} \left\{ \sum_{i=1}^N \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 \right\} \text{ sujeito a } \sum_{j=1}^p |\beta_j| \leq t$$

- Um $t \geq 0$ escolhido pelo usuário, que limita quanto de “massa” total os coeficientes podem gastar;
- Não é estimado a partir dos dados, é o parâmetro de ajuste do Lasso;
- $t = 0$ força todos os $\beta_j = 0$

- Cada valor de t é resolvido do zero;
- Escolher t por cross-validation multiplica esse custo;
- Sob correlação alta o Lasso escolhe um preditor e ignora os demais.

Por que a correlação atrapalha o Coordinate Descent?



A Reformulação

Forma de Penalização

$$\min_{(\beta_0, \beta)} \left\{ \underbrace{\frac{1}{2N} \sum_{i=1}^N \left(y_i - \underbrace{\beta_0}_{\text{Intercepto}} - \mathbf{x}_i^\top \beta \right)^2}_{\text{Perda}} + \underbrace{\lambda}_{\text{Peso}} \underbrace{P_\alpha(\beta)}_{\text{Penalidade}} \right\}$$


$$P_\alpha(\beta) = \sum_{j=1}^p \left[\underbrace{\frac{1 - \alpha}{2} \beta_j^2}_{\text{Ridge}} + \underbrace{\alpha |\beta_j|}_{\text{Lasso}} \right]$$

- Por dualidade Lagrangiana os dois problemas são equivalentes: para cada t existe um λ que resulta na mesma solução;
- α : Misturador $[0, 1]$.


A Reformulação

Objetivo em $p = 2$: Perda, Penalidade e Soma


(a) erro quadrático



(b) penalidade l1




(c) a soma, com a trajetória



A Reformulação



Mesmo corte com valores diferentes de Lambda



Warm Start

Um problema de otimização precisa de um ponto de partida. A escolha usual é arbitrária, tipicamente a origem, e o algoritmo gasta iterações só para chegar à vizinhança da resposta

O Warm Start substitui essa escolha arbitrária por uma informada: em vez de começar do zero, começa a partir da solução do problema anterior.




Active Set

Em uma solução esparsa, quase toda coordenada de um ciclo completo é apenas consultada;

Um conjunto ativo é $A = \{j : \beta_j \neq 0\}$, as coordenadas que estão dentro do modelo naquele momento;

A estratégia é alternar dois regimes. Um ciclo completo sobre as p coordenadas, que pode admitir variáveis novas, seguido de ciclos restritos a A .

Soft-Threshold



É o operador:

$$S(z, \gamma) = \text{sign}(z)(|z| - \gamma)_+ = \begin{cases} z - \gamma & , \text{se } z > 0 \text{ e } \gamma < |z| \\ z + \gamma & , \text{se } z < 0 \text{ e } \gamma < |z| \\ 0 & , \text{se } \gamma \geq |z|. \end{cases}$$

Trás z em direção a zero por uma quantidade fixa γ , e se isso o fizer cruzar o zero, pare no zero.

Algoritmo

Entrada: $\mathbf{X}$ de dimensão $N \times p$, $\mathbf{y}$ de comprimento N , $\alpha \in [0, 1]$, K , ϵ , pesos $\gamma_j \geq 0$, tolerância τ .

Atualização da coordenada j em λ ($\star$), usada nos passos 4.1 e 4.3:

$$\rho \leftarrow \langle \mathbf{x}_j, \mathbf{r} \rangle / N + \beta_j;$$

$$b \leftarrow S(\rho, \lambda \alpha \gamma_j) / (1 + \lambda(1 - \alpha) \gamma_j);$$

$$\Delta_j \leftarrow b - \beta_j;$$

se $\Delta_j \neq 0$: $\mathbf{r} \leftarrow \mathbf{r} - \mathbf{x}_j \Delta_j$ e $\beta_j \leftarrow b$.


1. Centre $\mathbf{y}$; centre e padronize as colunas de $\mathbf{X}$, guardando os desvios s_j .
2. $\lambda_{\max} = \max_{j: \gamma_j > 0} \frac{|\langle \mathbf{x}_j, \mathbf{y} \rangle|}{N \alpha \gamma_j}$; grade log-espçada $\lambda_1 = \lambda_{\max} > \dots > \lambda_K = \epsilon \lambda_{\max}$.
3. $\boldsymbol{\beta} \leftarrow \mathbf{0}$, $\mathbf{r} \leftarrow \mathbf{y}$ — **solução exata em λ_1** .
4. **para** $k = 1, \dots, K$ (*o $\boldsymbol{\beta}$ e o $\mathbf{r}$ persistem entre os k : é o **warm start**):
 1. Execute um **ciclo completo** aplicando ($\star$) a $j = 1, \dots, p$; seja $\delta = \max_j \Delta_j^2$.
 2. Se $\delta < (\tau \lambda_k)^2$: **convergiu**; guarde $\hat{\boldsymbol{\beta}}^{(k)} \leftarrow \boldsymbol{\beta}$ e passe ao próximo k .
 3. Caso contrário, itere ciclos restritos ao **active set** $A = \{j : \beta_j \neq 0\}$, aplicando ($\star$) a cada $j \in A$, até que $\max_{j \in A} \Delta_j^2 < (\tau \lambda_k)^2$; volte a 4.1.*
5. Desfaça a padronização: $\hat{\beta}_j \leftarrow \hat{\beta}_j / s_j$; $\hat{\beta}_0 = \bar{y} - \sum_j \hat{\beta}_j \bar{x}_j$.

Critério de Parada

Não é evidente no artigo. Remete a Tseng P. (2001) para convergência, não retoma o assunto.


Parar quando nenhum coeficiente mudar mais que um limiar fixo.

Limiar encolhe junto com lambda.



No último lambda, o limiar fixo viola as condições de otimalidade 3467× mais.
A linha proporcional é plana: violação relativa constante ao longo de todo o caminho.
Pontilhada em 1: violação do tamanho do próprio lambda. Aqui não é atingida.


Comparação com Tibshirani (1996)



Monte Carlo I

Warm Start + Active Set

EC1: custo de percorrer o caminho, por configuração



Cada visita custa $O(N)$. A contagem não depende da máquina.

Monte Carlo I

Warm Start + Active Set

- Warm Start reduz quantos ciclos são necessários;
- Active Set reduz o custo de cada ciclo.

Cenário	Configuração	Visitas (média)	Custo Relativo	Segundos
N > p	warm start + active set	21.353	1.00	0.135
	warm start	139.988	6.56	0.745
	active set	29.734	1.39	0.184
	nenhum dos dois	165.218	7.74	0.870
p > N	warm start + active set	78.614	1.00	0.353
	warm start	404.388	5.14	1.682
	active set	171.768	2.18	0.765
	nenhum dos dois	479.962	6.11	1.987

Monte Carlo II

Validação Cruzada vs Critérios Analíticos (1996)

- 1996 :

Critérios analíticos atraentes → Cross-validation cara
 K folds sobre uma grade de G valores custam $K \times G$
execuções e independentes do otimizador, mais o ajuste.

- 2010 :

Cross-validation custa $K+1$ caminhos → Caminho inteiro
custa da ordem de um único ajuste


- Experimento:

- 50 valores de λ e 5 folds;
- $N = 150$, $p = 60$;
- 6 efeitos verdadeiros (posições 1, 11, 21, 31, 41 e 51);
- 54 variáveis têm coeficiente exatamente zero;
- Correlação entre i e j é p elevado à distância entre elas. Vizinhas são muito parecidas, distantes quase independentes;
- 20 réplicas por cenário. Cada réplica gera dados novos;
- Conjunto de teste de 2.000 observações.

Monte Carlo II

Validação Cruzada vs Critérios Analíticos (1996)


Qual critério prediz melhor?



Monte Carlo II

Validação Cruzada vs Critérios Analíticos (1996)



O que cada critério faz com a seleção?



Contribuição

Ordem de Visita das Coordenadas


- Geometria do Vale



Contribuição

Ordem de Visita das Coordenadas



- Pontos Ótimos



Contribuição

Ordem de Visita das Coordenadas

- Velocidade




Aplicação

Contexto:

Communities and Crime


(Redmond, 2002; UCI, DOI 10.24432/C53W3X, CC BY 4.0)

- 1994 comunidades dos EUA;
- 100 preditores após a limpeza;
- Resposta = crimes violentos por 100 mil habitantes;
- Foram descartadas 22 variáveis por excesso de faltantes;
- Não é o conjunto do artigo (expressão genética) nem o dos tutoriais do glmnet.




Aplicação

Caminho:



Aplicação

Escolha do Lambda:



Regra	Lambda	Tamanho	EQM no Teste	vs MQO
CV (mínimo)	0.00088	56	0.01788	-4.1%
CV (1 EP)	0.01017	14	0.01881	+0.9%
AIC	0.00011	89	0.01822	-2.3%
BIC	0.00480	20	0.01821	-2.3%
GCV	0.00073	60	0.01787	-4.2%
MQO	0.00000	100	0.01864	+0.0%

Aplicação


Determinando novo critério:

Apertar a tolerância resolve a ambiguidade

Círculo cinza: critério absoluto.

Círculo branco: proporcional a lambda.

Das 16 instáveis, 5 passam a entrar sempre e 11 a nunca entrar.



Uso de IA

1. Implementação de Códigos R
2. Plots e ideias de formas de visualização
3. Sugestões de contribuições originais
4. Auxílio na busca de Dataset real para aplicação

Conclusão

1. Paper 1996:

- Critérios analíticos existiam em boa parte para contornar o custo do cálculo.

2. Warm Starts e Active Set:

- Base de todo o artigo. Trouxe ganho significativo para a otimização e ponto que não tinha em 96.

3. Monte Carlo I:


- As 4 configurações atingem o mesmo valor objetivo, com diferença relativa de $6,5e-11$.
- O Active Set é o elemento dominante, abrir mão dele prejudica mais do que abrir mão do Warm Starts, porque o preço de cada ciclo pesa mais do que o número de ciclos.
- Os ganhos não se multiplicam, o Warm Starts que mantém o conjunto ativo pequeno.

4. Monte Carlo II:

- Comparando os critérios, a cross-validation no mínimo tem o menor erro de predição nos três níveis de correlação, e a regra de 1 erro-padrão o maior.
- Critérios analíticos ficam no meio, e a diferença entre eles é uma troca entre achar efeitos verdadeiros e admitir falsos positivos.

5. Ordem de Visita:

- Impacta o resultado do otimizador.
- Possui melhor custo computacional para casos de correlação intermediária.

The background is a solid dark blue. On the left and right sides, there are decorative elements consisting of several concentric white circles. Overlaid on these circles are large, semi-transparent blue shapes that create a layered effect. The text 'Obrigado (a)' is centered in the middle of the image in a white, serif font.

Obrigado (a)



REGULARIZATION PATHS FOR GENERALIZED LINEAR MODELS VIA COORDINATE DESCENT

J. Friedman T. Hastie R. Tibshirani

Aline Gabrielly Gomes de Freitas
Luiz Eduardo de Souza

Porto Alegre, 01 de setembro de 2026.